


تاریخ: ۱۴۰۱/۹/۲۷

شماره دانشجویی: ۸۱۰۱۰۱۱۷۷

زهره رحمانیان


(A)



① الف) برای طبقه بندی شکل A به یک منصف نیاز داریم و بنابراین از لایه مخفی استفاده می‌کنیم. ورودی، مختصات نقاط است که x_1 و x_2 آن‌ها را نامیدیم و سه نورون در لایه مخفی که یکی از آن‌ها بایاس است در نظر گرفته می‌شود و خروجی یکی نورون است. 0 یعنی آبر و 1 یعنی قرمز است.

$$y = 0 \text{ or } 1$$

(B)



برای طبقه بندی شکل B، به دو خط نیاز داریم برای همین به لایه مخفی نیاز داریم. ورودی، مختصات نقاط است که x_1 و x_2 آن‌ها را نامیدیم و سه نورون در لایه مخفی اول که یکی از آن‌ها بایاس است در نظر گرفته می‌شود. خروجی دوم هم به همین صورت. خروجی شامل ۳ نورون است که هر یک از رنگ‌ها را مشخص می‌کند.

(A)

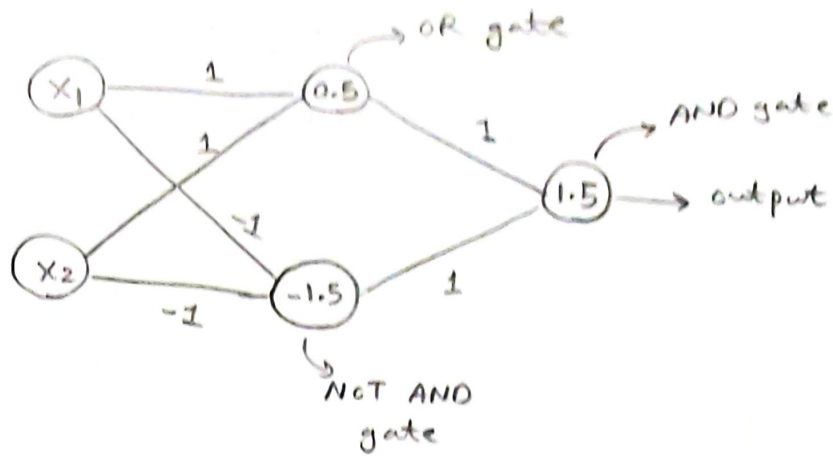
x_1	x_2	
0	0	$\rightarrow z = 0 \xrightarrow{z > -0.15} y = 1$
0	1	$\rightarrow z = -0.1 \xrightarrow{z > -0.15} y = 1$
1	0	$\rightarrow z = -0.1 \xrightarrow{z > -0.15} y = 1$
1	1	$\rightarrow z = -0.2 \xrightarrow{z < -0.15} y = 0$

(ب) همان طور که مشاهده می‌شود عملگر AND یا همان NAND را دارد.

(B)

x_1	x_2	
0	0	$\rightarrow z = 0 \xrightarrow{z > -0.05} y = 1$
0	1	$\rightarrow z = -0.1 \xrightarrow{z < -0.05} y = 0$
1	0	$\rightarrow z = -0.1 \xrightarrow{z < -0.05} y = 0$
1	1	$\rightarrow z = -0.2 \xrightarrow{z < -0.05} y = 0$

همان طور که مشاهده می‌شود عملگر OR یا همان NOR را دارد.



مقادیر داخل نورون‌ها می‌تواند مثبت و منفی و صفر باشد. مقدار آستانه تغییر می‌کند.

X_1	X_2	
0	0	$\rightarrow 0 \times 1 + 1 \times 1 = 1 \rightarrow Y = 0 \checkmark$
0	1	$\rightarrow 1 \times 1 + 1 \times 1 = 2 \rightarrow Y = 1 \checkmark$
1	0	$\rightarrow 1 \times 1 + 1 \times 1 = 2 \rightarrow Y = 1 \checkmark$
1	1	$\rightarrow 1 \times 1 + 0 \times 1 = 1 \rightarrow Y = 0 \checkmark$

$$Z_1 = w_{01} + w_{11}X_1 + w_{21}X_2$$

$$Z_2 = w_{02} + w_{12}X_1 + w_{22}X_2$$

$$a_1 = \sigma(Z_1) = \frac{1}{1 + e^{-Z_1}}$$

$$a_2 = \sigma(Z_2) = \frac{1}{1 + e^{-Z_2}}$$

$$Y = v_0 + v_1 a_1 + v_2 a_2 = \text{predicted}$$

$$\text{Error} = 0.5 (\text{predicted} - \text{target})^2$$

$$\frac{d\text{Error}}{dv_0} = \frac{d\text{Error}}{d\text{predicted}} \times \frac{d\text{predicted}}{dv_0}$$

$$v_0 = v_0' - \alpha \frac{d\text{Error}}{dv_0}$$

$$\frac{d\text{Error}}{dv_1} = \frac{d\text{Error}}{d\text{predicted}} \times \frac{d\text{predicted}}{dv_1}$$

$$v_1 = v_1' - \alpha \frac{d\text{Error}}{dv_1}$$

$$\frac{d\text{Error}}{dv_2} = \frac{d\text{Error}}{d\text{predicted}} \times \frac{d\text{predicted}}{dv_2}$$

$$v_2 = v_2' - \alpha \frac{d\text{Error}}{dv_2}$$

$$\frac{dError}{dw_{01}} = \frac{dError}{dpredicted} \times \frac{dpredicted}{da_1} \times \frac{da_1}{dz_1} \times \frac{dz_1}{dw_{01}} \quad w_{01} = w'_{01} - \alpha \frac{dError}{dw_{01}}$$

$$\frac{dError}{dw_{11}} = \frac{dError}{dpredicted} \times \frac{dpredicted}{da_1} \times \frac{da_1}{dz_1} \times \frac{dz_1}{dw_{11}} \quad w_{11} = w'_{11} - \alpha \frac{dError}{dw_{11}}$$

$$\frac{dError}{dw_{21}} = \frac{dError}{dpredicted} \times \frac{dpredicted}{da_1} \times \frac{da_1}{dz_1} \times \frac{dz_1}{dw_{21}} \quad w_{21} = w'_{21} - \alpha \frac{dError}{dw_{21}}$$

$$\frac{dError}{dw_{02}} = \frac{dError}{dpredicted} \times \frac{dpredicted}{da_2} \times \frac{da_2}{dz_2} \times \frac{dz_2}{dw_{02}} \quad w_{02} = w'_{02} - \alpha \frac{dError}{dw_{02}}$$

$$\frac{dError}{dw_{12}} = \frac{dError}{dpredicted} \times \frac{dpredicted}{da_2} \times \frac{da_2}{dz_2} \times \frac{dz_2}{dw_{12}} \quad w_{12} = w'_{12} - \alpha \frac{dError}{dw_{12}}$$

$$\frac{dError}{dw_{22}} = \frac{dError}{dpredicted} \times \frac{dpredicted}{da_2} \times \frac{da_2}{dz_2} \times \frac{dz_2}{dw_{22}} \quad w_{22} = w'_{22} - \alpha \frac{dError}{dw_{22}}$$

: ($\alpha = 0.2$) cruc cr

$$Z_1 = 1.1 \quad Z_2 = 0.19 \quad a_1 = 0.75 \quad a_2 = 0.55$$

$$Y = 0.13 \quad Error = 0.008$$

$$\frac{dError}{dv_0} = 0.5 \times 2 (\text{predicted} - \text{target}) \times 1 = 0.13 \quad v_0 = -0.3 - 0.2 \times 0.13 = -0.326$$

$$\frac{dError}{dv_1} = 0.5 \times 2 (\text{predicted} - \text{target}) \times a_1 = 0.097 \quad v_1 = 0.5 - 0.2 \times 0.097 = 0.4806$$

$$\frac{dError}{dv_2} = 0.5 \times 2 (\text{predicted} - \text{target}) \times a_2 = 0.071 \quad v_2 = 0.1 - 0.2 \times 0.071 = 0.0858$$

$$\frac{dError}{dw_{01}} = 0.5 \times 2 (\text{predicted} - \text{target}) \times v_1 \times \frac{e^{-z_1}}{(1 + e^{-z_1})^2} \times 1 = 0.012 \quad w_{01} = 0.4 - 0.2 \times 0.012 = 0.39$$

$$\frac{dError}{dw_{11}} = 0.5 \times 2 (\text{predicted} - \text{target}) \times v_1 \times \frac{e^{-z_1}}{(1 + e^{-z_1})^2} \times x_1 = 0.012 \quad w_{11} = 0.7 - 0.2 \times 0.012 = 0.69$$

$$\frac{dError}{dw_{21}} = 0.5 \times 2 (\text{predicted} - \text{target}) \times v_1 \times \frac{e^{-z_1}}{(1 + e^{-z_1})^2} \times x_2 = 0 \quad w_{21} = -0.2 - 0.2 \times 0 = -0.2$$

$$\frac{dError}{dw_{02}} = 0.5 \times 2 (\text{predicted} - \text{target}) \times v_2 \times \frac{e^{-z_2}}{(1+e^{-z_2})^2} \times 1 = 0.003 \quad w_{02} = 0.6 - 0.2 \times 0.003 = 0.598$$


$$\frac{dError}{dw_{12}} = 0.5 \times 2 (\text{predicted} - \text{target}) \times v_2 \times \frac{e^{-z_2}}{(1+e^{-z_2})^2} \times x_1 = 0.003 \quad w_{12} = -0.4 - 0.2 \times 0.003 = -0.402$$

$$\frac{dError}{dw_{22}} = 0.5 \times 2 (\text{predicted} - \text{target}) \times v_2 \times \frac{e^{-z_2}}{(1+e^{-z_2})^2} \times x_2 = 0 \quad w_{22} = 0.3 - 0.2 \times 0 = 0.3$$

$$H(Y|X=\text{ارزان}) = -\frac{1}{2} \log \frac{1}{2} - \frac{1}{2} \log \frac{1}{2} = -\log \frac{1}{2} = 0.3$$

$$H(Y|X=\text{گران}) = -\frac{1}{3} \log \frac{1}{3} - \frac{2}{3} \log \frac{2}{3} = 0.27$$


$$H(Y) = \frac{4}{10} \times 0.3 + \frac{6}{10} \times 0.27 = 0.282$$



$$H(Y|X=\text{نفس}) = -\frac{1}{4} \log \frac{1}{4} - \frac{3}{4} \log \frac{3}{4} = 0.244$$

$$H(Y|X=\text{بیش}) = -\frac{1}{6} \log \frac{1}{6} - \frac{5}{6} \log \frac{5}{6} = 0.195$$

$$H(Y) = \frac{4}{10} \times 0.244 + \frac{6}{10} \times 0.195 = 0.214$$




$$H(Y|X=\text{آبی}) = -\frac{1}{4} \log \frac{1}{4} - \frac{3}{4} \log \frac{3}{4} = 0.244$$


$$H(Y|X=\text{سبز}) = 0 - 1 \log 1 = 0$$

$$H(Y|X=\text{قرمز}) = -\frac{1}{4} \log \frac{1}{4} - \frac{3}{4} \log \frac{3}{4} = 0.244$$

$$H(Y) = \frac{4}{10} \times 0.244 + \frac{2}{10} \times 0 + \frac{4}{10} \times 0.244 = \frac{8}{10} \times 0.244 = 0.195$$



از آن جایی که اکثری برای رنگ از دو ویژگی رنگ بهره گرفته است پس این ویژگی را در ریشه قرار می دهیم و بر حسب اکثریت را به برگ رنگت می دهیم:



$$\text{دقت} = \frac{TP+TN}{TP+FP+TN+FN} = \frac{8}{10} = 0.8$$

$$\text{حسب} = \frac{TP}{TP+FP} = \frac{3}{4} = 0.75$$

(۴) الف) میانگین تخمین یارزن به صورت زیر حساب می شود :

$$\bar{p}_n(x) = E[p_n(x)] = E\left[\frac{1}{n} \sum_{i=1}^n \frac{1}{v_n} \phi\left(\frac{x-x_i}{h_n}\right)\right] = \frac{1}{n} \times n E_y\left[\frac{1}{v_n} \phi\left(\frac{x-y}{h_n}\right)\right]$$

$$= \int \frac{1}{v_n} \phi\left(\frac{x-y}{h_n}\right) p(y) dy = \frac{1}{v_n} \int p(y) \phi\left(\frac{x-y}{h_n}\right) dy$$

طبق فرض سوال $p(y) \sim U(0, a)$ که یعنی اگر خارج بازه $0 < y < a$ باشد $p(y) = 0$ می شود.

$$x < 0 \rightarrow \bar{p}_n(x) = \frac{1}{v_n} \int_{-\infty}^{+\infty} p(y) \phi\left(\frac{x-y}{h_n}\right) dy = \frac{1}{v_n} \int_0^a p(y) \phi\left(\frac{x-y}{h_n}\right) dy$$

$$\begin{aligned} & \xrightarrow[0 < y < a]{\substack{x < y \rightarrow \frac{x-y}{h_n} < 0 \\ h_n > 0}} = \frac{1}{v_n} \int_0^a p(y) \times 0 dy = 0 \end{aligned}$$

$$0 \leq x \leq a \rightarrow \bar{p}_n(x) = \frac{1}{v_n} \int_{-\infty}^{+\infty} p(y) \phi\left(\frac{x-y}{h_n}\right) dy = \frac{1}{h_n} \int_0^x \frac{1}{a} \exp\left(\frac{y-x}{h_n}\right) dy$$

$$= \frac{1}{a h_n} h_n \exp\left(\frac{y-x}{h_n}\right) \Big|_0^x = \frac{1}{a} (1 - \exp\left(\frac{-x}{h_n}\right))$$

$$= \frac{1}{a} (1 - e^{-\frac{x}{h_n}})$$

$$x \geq a \rightarrow \bar{p}_n(x) = \frac{1}{v_n} \int_{-\infty}^{+\infty} p(y) \phi\left(\frac{x-y}{h_n}\right) dy = \frac{1}{h_n} \int_0^a \frac{1}{a} \exp\left(\frac{y-x}{h_n}\right) dy$$

$$= \frac{1}{a h_n} h_n \exp\left(\frac{y-x}{h_n}\right) \Big|_0^a = \frac{1}{a} (\exp\left(\frac{a-x}{h_n}\right) - \exp\left(\frac{-x}{h_n}\right))$$

$$= \frac{1}{a} (\exp\left(\frac{a}{h_n}\right) - 1) \exp\left(\frac{-x}{h_n}\right)$$

$$= \frac{1}{a} (e^{\frac{a}{h_n}} - 1) e^{-\frac{x}{h_n}}$$

ب) بایس برابر $E(p(x) - \hat{p}(x)) = p(x) - \bar{p}(x)$ است. بایس شبیه به صورت زیر محاسب می شود :

طبق فرض سوال در بازه $0 \leq x < a$ داریم

$$\text{bias}(x) = \frac{|p(x) - \bar{p}(x)|}{p(x)} = \frac{\frac{1}{a} - \bar{p}(x)}{\frac{1}{a}} = 1 - a \bar{p}(x) = 1 - a \times \frac{1}{a} (1 - e^{-\frac{x}{h_n}}) = e^{-\frac{x}{h_n}}$$

بایس در بازه $0 < x < a$ کاهش می یابد پس اگر بخواهیم که اندازه بایس تخمین یارزن، در ۹۹٪ از طول

بازه $0 \leq x < a$ کمتر از یک درصد یا همان ۰.۰۱ باشد نیاز است که رابطه‌ی زیر را محاسبه کنیم :

$$\text{bias} \left(\frac{a}{100} \right) = 0.01 \rightarrow e^{-a/100 h_n} = 0.01$$

$$\xrightarrow{\ln} -\frac{a}{100 h_n} = -\ln 100 \rightarrow \boxed{h_n = a / (100 \ln 100)}$$

⑤ ابتدا کتابخانه های مورد نیاز را import می کنیم . سپس داده های iris را لود می کنیم .

هر کدام از داده های مربوط به نوع setosa و versicolor را در دو دسته فریم قرار می دهیم و در نهایت نمودار نقاط آن ها را در یک نمودار رسم می کنیم .

ابتدا به آماده سازی داده ها می پردازیم . از داده ها ، آن هایی که نوعشان setosa یا versicolor است را انتخاب می کنیم . x که همان ویژگی های sepal length, sepal width هستند و y که فریم است را جدا می کنیم . نوع setosa را به 1 و versicolor را به 0 map می کنیم که عملیات را راحت تر انجام دهیم . داده های test و train را جدا می کنیم . در نهایت تابع train-perceptron را با $\alpha = 10^{-6}$ و نرخ یادگیری 1000 اجرا می کنیم .

این تابع به این صورت عمل می کند که ابتدا bias و وزن های اولیه را 0 قرار می دهد . سپس در هر α به این صورت عمل می کند :

به ازای هر x ، ابتدا label آن را predict می کند . برای این کار تابع predict را فراخوانی می کند . این تابع به این صورت عمل می کند که حاصل $w x$ یعنی ضرب داخلی x و وزن های فعلی را حساب می کند و با b مقایسه می کند . اگر بزرگتر از مساری b بود 1 وگرنه 0 برمی گرداند . بعد از این مراحل نوبت به بروز رسانی وزن ها و b با استفاده از gradient descent می رسد که به این صورت است :

$$w_k = w_k - \alpha \frac{\partial \text{error}}{\partial w_k} \rightarrow w_k = w_k + \alpha (y - \hat{y}) x_k^{(i)}$$

$$b = b - \alpha \frac{\partial \text{error}}{\partial b} \rightarrow b = b + \alpha (y - \hat{y})$$

که بر این معنا که آن ها زده شد و در نهایت b و w به روز رسانی می شود . وزن های به روز رسانی شده

به این صورت بود : $[-4.8e^{-9}, 8.8e^{-9}]$ و bias به این صورت است : $2e^{-9}$

که چون از b به عنوان threshold استفاده کردیم معادله خط به این صورت در می آید :

$$w_1 x_1 + w_2 x_2 - b = 0 \rightarrow x_2 = -(w_1 x_1 - b) / w_2$$

$$-w_1/w_2 = 0.54$$

که شیب خط برابر می‌شود با :


$$b/w_2 = 0.2272$$

و عرض از مبدأ برابر است با :

دقت این الگوریتم نیز به دست آورده شده است که برابر 98.75٪ می‌باشد.

برای این کار تابع $test-perceptron$ فراخوانی شده است. که به ازای هر x داده شده، آن را با استفاده از وزن‌های بدست آمده در مرحله $train$ و $threshold$ که آن همان b بدست آمده در مرحله $train$ است، $predict$ می‌کند. اگر مقدار پیش‌بینی شده درست بود یک واحد به تعداد پیش‌بینی درست اضافه می‌کند و در نهایت دقت را بدست آورده و گزارش می‌کند.

خط بدست آمده برای جدا کردن داده‌های دو گونه گفته شده در سوال به دست می‌آید :



⑧ ابتدا با استفاده از دستورات داده شده ، داده ها تولید شد ، سپس هسته گرام آن ها را رسم کردم که یک دید کلی نسبت به داده ها پیدا کنم .

در مرحله بعد پنجره ی وایزین را برای سازه کردم ، که اساس کار آن طبق فرمول زیر می باشد:

$$KDE = \sum_{i=1}^n \frac{1}{h\sqrt{2\pi}} e^{-0.5 \left(\frac{x-x_i}{h} \right)^2}$$

ابتدا به تعداد داده های که تولید کردم ، یک دنباله ی عددی که min و max و تعداد آن برابر داده ی تولید شده است ، با استفاده از دستور np.linspace تولید می کنم و آن ها را در متغیر points می زنم .


سپس به ازای هر x_i در داده ای که اول تولید کردم ، یک توزیع گاوسی با فرمول $\frac{1}{h\sqrt{2\pi}} e^{-0.5 \left(\frac{x-x_i}{h} \right)^2}$

که x همان points است ، در نظر می گیریم و مجموع این توزیع ها را بر می گردانیم . به ازای ۳ مقدار مختلف برای h ، این تابع را صدا می زنیم . ابتدا $h=0.1$ را امتحان کردم و نتیجه یک توزیع تقریباً ایساکی شد که نوزده یاری دارد.


مرحله بعد تابع را با $h=1$ صدا زدم که یک توزیع smooth و ساده تر نسبت به قبلی بدست آمد.

مرحله بعد تابع را با $h=10$ صدا زدم که یک توزیع تقریباً flat بدست آمد و underfit بود یعنی توزیع مناسب دیتای که داریم نیست .


می توان نتیجه گرفت با افزایش h ، تعین توزیع smooth تر و ساده تر می شود و برعکس با کاهش آن تعین توزیع پیچیده تر می شود و اگر خیلی کوچک باشد یک توزیع ایساکی که نوزده یاری دارد می دهد . این همان ویژگی وایزین است که با افزایش اندازه پنجره یک توزیع احتمال نرم smooth می دهد و با کاهش آن توزیع احتمال پیچیده تر می شود و اگر خیلی کوچک باشد توزیع احتمال ایساکی می شود و متدها با شیب زیاد داریم .



$h = 0.1$



$h = 1$



$h = 10$